

به نام خدا



پروژه درس جبر خطی - ترم ۴۰۴۲

Latent Semantic Indexing

استاد : دکتر نیکان

اعضای گروه: علی کارخانه - مصطفی شیبانی - حسین نادری - مرتضی رحیمی

سوالات مفهومی:

۱. از روش‌های ارزش‌گذاری کلمات در متون، روش‌های TF و IDF را توضیح دهید. چرا مطالعه مستقل این دو روش ممکن است گمراه‌کننده باشد؟

تعریف TF: Term Frequency مخفف است؛ یعنی یک واژه چند بار در یک سند تکرار شده است. اگر واژه‌ای فقط یک بار در سند آمده باشد، آنگاه:

$$TF = 1$$

تعریف IDF: Inverse Document Frequency مخفف است؛ یعنی آن واژه در کل مجموعه اسناد چقدر نادر یا رایج است. فرمول رایج آن:

$$IDF(t) = \log \left(\frac{N}{df(t)} \right)$$

که در آن:

- N : تعداد کل اسناد
 - $df(t)$: تعداد اسنادی که واژه t در آن‌ها آمده است
- هرچه یک واژه در اسناد کمتری دیده شود، IDF بزرگ‌تر می‌شود.

چرا مطالعه مستقل TF و IDF ممکن است گمراه‌کننده باشد؟

چون هر کدام فقط یک بعد از اهمیت واژه را نشان می‌دهند و به‌تنهایی کافی نیستند.

- اگر فقط به TF نگاه کنیم، ممکن است واژه‌ای در یک سند خیلی زیاد تکرار شود، اما اصلاً واژه مهمی نباشد. مثلاً کلماتی مثل: (است، در، و). این‌ها ممکن است TF بالایی داشته باشند، ولی چون در تقریباً همه اسناد هستند، برای تشخیص موضوع سند مفید نیستند. پس TF بالا لزوماً به معنی مهم بودن واژه نیست.
- اگر فقط به IDF نگاه کنیم، ممکن است واژه‌ای در کل مجموعه نادر باشد، اما در سند موردنظر فقط یک‌بار و آن هم به‌صورت حاشیه‌ای آمده باشد. مثلاً نام یک مکان یا عدد خاص که فقط یک بار در متن آمده و نقش اصلی در موضوع سند ندارد. پس IDF بالا هم به‌تنهایی لزوماً به معنی مهم بودن در آن سند خاص نیست.

۲. یکی از روش‌های تعیین آستانه مقادیر تکین برای کاهش مرتبه (Truncated SVD) رویکرد «نقطه زانویی» است. این رویکرد را شرح دهید.

در روش Truncated SVD هدف این است که به جای نگاه داشتن همه مقادیر تکین، فقط چند مقدار تکین مهم‌تر را حفظ کنیم تا مرتبه ماتریس کاهش یابد. اگر ماتریس داده را به صورت زیر تجزیه کنیم:

$$A = U \Sigma V^T$$

در ماتریس Σ ، مقادیر تکین به صورت نزولی مرتب می‌شوند:

$$\sigma_1 \geq \sigma_2 \geq \sigma_3 \geq \dots \geq \sigma_r$$

در Truncated SVD باید تصمیم بگیریم چند مقدار تکین اول را نگه داریم؛ یعنی مقدار k را انتخاب کنیم.

ایده اصلی نقطه زانویی:

در بسیاری از داده‌ها، مقادیر تکین ابتدایی بزرگ هستند و بخش اصلی اطلاعات را نگه می‌دارند. اما بعد از مدتی، مقدارهای تکین خیلی کوچک می‌شوند و کاهش آن‌ها آهسته‌تر می‌شود. اگر مقادیر تکین را روی نمودار رسم کنیم:

• محور افقی: شماره مؤلفه یا شماره مقدار تکین

• محور عمودی: اندازه مقدار تکین

معمولاً نمودار در ابتدا کاهش زیادی دارد و سپس تقریباً صاف می‌شود. نقطه‌ای که در آن نمودار از حالت افت سریع به حالت افت آهسته تغییر می‌کند، به نام **نقطه زانویی** (Elbow Point یا Knee Point) شناخته می‌شود.

انتخاب آستانه با نقطه زانویی:

در این روش، مقدار k را برابر با شماره نقطه زانویی انتخاب می‌کنیم. پس مقادیر تکین زیر نگه داشته می‌شود:

$$\sigma_1, \sigma_2, \dots, \sigma_k$$

و بقیه مقادیر تکین حذف می‌شوند:

$$\sigma_{k+1}, \sigma_{k+2}, \dots$$

مثال: فرض کنید مقادیر تکین به شکل زیر باشند:

$$100, 80, 60, 40, 20, 5, 4, 3.8, 3.5, 3.3$$

در اینجا تا مقدار پنجم کاهش زیاد است، اما بعد از آن مقادیر خیلی آهسته کم می‌شوند. پس نقطه زانویی حدوداً در $k = 5$ است؛ یعنی ۵ مقدار تکین اول را نگه می‌داریم و بقیه را حذف می‌کنیم.

دلیل استفاده از نقطه زانو:

• **حفظ اطلاعات مهم:** مقادیر تکین بزرگ‌تر معمولاً بیانگر ساختار اصلی داده هستند.

• **حذف نویز و کاهش پیچیدگی:** مقادیر تکین کوچک‌تر معمولاً شامل جزئیات کم‌اهمیت یا نویز هستند.

پس با انتخاب نقطه زانویی، سعی می‌کنیم تا جایی مؤلفه‌ها را نگه داریم که هنوز اطلاعات قابل‌توجهی اضافه می‌کنند.

۳. نحوه محاسبه خطای بازسازی در Truncated SVD را بیان کنید.

در Truncated SVD ماتریس اصلی A را با یک ماتریس تقریبی کم‌مرتبه بازسازی می‌کنیم. اگر تجزیه SVD ماتریس A به صورت زیر باشد:

$$A = U \Sigma V^T$$

آنگاه در نسخه برش‌خورده، فقط k مقدار تکین اول را نگه می‌داریم:

$$A_k = U_k \Sigma_k V_k^T$$

که در آن:

- U_k شامل k بردار ویژه چپ اول است.
- Σ_k شامل k مقدار تکین بزرگتر است.
- V_k شامل k بردار ویژه راست اول است.

خطای بازسازی برابر است با اختلاف بین ماتریس اصلی و ماتریس بازسازی شده:

$$E = A - A_k$$

برای اندازه‌گیری بزرگی این خطا، معمولاً از یک نرم استفاده می‌شود.
نرم فروبنیوس (Frobenius Norm): رایج‌ترین معیار برای این کار است:

$$\|A - A_k\|_F$$

که به این خطا، **خطای فروبنیوس** می‌گویند. این نرم از رابطه زیر به دست می‌آید:

$$\|A - A_k\|_F = \sqrt{\sum_{i,j} (A_{ij} - (A_k)_{ij})^2}$$

یعنی: ریشه مجموع مربعات اختلاف درایه‌های ماتریس اصلی و بازسازی شده.
نکته: در Truncated SVD خطای بازسازی فروبنیوس را می‌توان مستقیماً از مقادیر تکین حذف‌شده محاسبه کرد:

$$\|A - A_k\|_F = \sqrt{\sigma_{k+1}^2 + \sigma_{k+2}^2 + \dots + \sigma_r^2}$$

که r رتبه اصلی ماتریس است. یعنی: خطای بازسازی برابر است با ریشه مجموع مربعات مقادیر تکینی که حذف شده‌اند.

نرم طیفی (Spectral Norm): گاهی از نرم طیفی هم استفاده می‌شود:

$$\|A - A_k\|_2 = \sigma_{k+1}$$

یعنی در این معیار، خطای بازسازی برابر با **اولین مقدار تکین حذف‌شده** است.

تفسیر:

- اگر k را بزرگ‌تر بگیریم، مقادیر تکین بیشتری نگه داشته می‌شود.
- در نتیجه، خطای بازسازی کوچک‌تر می‌شود.
- اگر همه مقادیر تکین را نگه داریم، آنگاه $A_k = A$ و خطا صفر می‌شود.

مثال:

فرض کنید مقادیر تکین یک ماتریس چنین باشد:

$$\sigma_1 = 10, \quad \sigma_2 = 7, \quad \sigma_3 = 4, \quad \sigma_4 = 2$$

اگر فقط دو مقدار اول را نگه داریم ($k=2$)، خطای بازسازی فروبنیوس برابر است با:

$$\|A - A_k\|_F = \sqrt{4^2 + 2^2} = \sqrt{16 + 4} = \sqrt{20}$$

و خطای طیفی برابر است با:

$$\|A - A_k\|_2 = 4$$

۴. دو معیار شباهت بردارهای عددی، Cosine Similarity و Euclidean Distance را ضمن ارائه روابط ریاضی، توضیح دهید. بیشینه و کمینه این دو معیار را تفسیر کنید.

• **معیار فاصله اقلیدسی (Euclidean Distance):** این معیار که بر پایه نرم دوم (L2-Norm) بنا شده است، فاصله مستقیم خطی میان دو نقطه در یک فضای برداری $\mathbb{R}^n$ را محاسبه می‌کند. این معیار به مختصات مکانی و بزرگی (Magnitude) بردارها به شدت حساس است.
رابطه ریاضی: برای دو بردار $A, B \in \mathbb{R}^n$:

$$d(A, B) = \|A - B\|_2 = \sqrt{\sum_{i=1}^n (A_i - B_i)^2}$$

تفسیر کرانه‌ها:

– **کمینه (Minimum):** مقدار صفر. از نظر هندسی زمانی رخ می‌دهد که دو نقطه کاملاً بر هم منطبق باشند ($A = B$).
– **بیشینه (Maximum):** بی‌نهایت ($+\infty$). با دور شدن نقاط از یکدیگر در فضای برداری، این مقدار بدون کران افزایش می‌یابد.

• **معیار شباهت کسینوسی (Cosine Similarity):** شباهت کسینوسی اندازه زاویه بین دو بردار را می‌سنجد و در فضای پردازش متن (LSI) کاربرد فراوانی دارد، زیرا مستقل از طول اسناد (بزرگی بردارها) عمل کرده و صرفاً جهت‌گیری معنایی را ارزیابی می‌کند.
رابطه ریاضی: این معیار برابر با حاصل ضرب داخلی نرمال‌شده‌ی دو بردار است:

$$\text{Sim}_{\cos}(A, B) = \cos(\theta) = \frac{\langle A, B \rangle}{\|A\|_2 \|B\|_2} = \frac{\sum_{i=1}^n A_i B_i}{\sqrt{\sum_{i=1}^n A_i^2} \sqrt{\sum_{i=1}^n B_i^2}}$$

تفسیر کرانه‌ها:

– **بیشینه (۱):** نشان‌دهنده زاویه $\theta = 0^\circ$ است. یعنی دو بردار دقیقاً هم‌راستا (Collinear) هستند و حداکثر شباهت موضوعی را دارند.
– **مقدار صفر (۰):** نشان‌دهنده زاویه $\theta = 90^\circ$ است. دو بردار متعامد (Orthogonal) هستند و هیچ همپوشانی و شباهتی با هم ندارند.
– **کمینه (-۱):** نشان‌دهنده زاویه $\theta = 180^\circ$ است. دو بردار در خلاف جهت هم قرار دارند (تضاد کامل).
نکته تحلیلی (ارتباط دو معیار): اگر بردارهای A و B نرمال‌سازی شوند (یعنی $\|A\| = \|B\| = 1$)، رابطه مستقیم زیر بین فاصله اقلیدسی و شباهت کسینوسی برقرار است:

$$d^2(A, B) = \|A - B\|^2 = \|A\|^2 + \|B\|^2 - 2\langle A, B \rangle = 2 - 2\cos(\theta)$$

۵. ابتدا درباره استاندارد کردن بردارهای عددی جست و جو کنید. سپس ضمن ارائه رابطه ریاضی، درباره لزوم استاندارد کردن ماتریس داده‌ها، پیش از تجزیه آن بحث کنید.

تعریف علمی و ریاضی استانداردسازی (Z-score Normalization):

استانداردسازی فرآیندی است که توزیع داده‌های هر ویژگی (ستون‌های ماتریس) را به یک توزیع با میانگین صفر ($\mu = 0$) و واریانس واحد ($\sigma^2 = 1$) تبدیل می‌کند. در شکل ماتریسی، اگر X ماتریس داده‌ها با ابعاد $m \times n$ باشد، ماتریس استانداردشده Z به صورت زیر استخراج می‌شود:

$$Z_{ij} = \frac{X_{ij} - \mu_j}{\sigma_j}$$

که در آن μ_j میانگین ویژگی j -ام و σ_j انحراف معیار آن است.

تحلیل ضرورت اعمال استانداردسازی پیش از تجزیه (SVD/PCA):

تجزیه مقادیر تکین (SVD) معادل با یافتن بردارهای ویژه ماتریس کوواریانس (یا ماتریس گرام $X^T X$) است. الگوریتم SVD ذاتاً به دنبال جهت‌هایی در فضای ویژگی می‌گردد که بیشترین پراکندگی (واریانس) را در امتداد خود دارند.

(آ) **جولوگیری از تسلط مقیاس‌های بزرگ (Scale Domination):** اگر یک ویژگی دامنه عددی بزرگی داشته باشد (مثلاً واحد اندازه‌گیری به میلیون باشد) و ویژگی دیگر کوچک باشد (مثلاً بین ۰ تا ۱)، ویژگی اول واریانس بسیار بزرگی تولید می‌کند. در نتیجه، SVD اولین بردار تکین راست (V_1) را تقریباً موازی با محور ویژگی اول قرار می‌دهد و ساختار واقعی داده‌ها نادیده گرفته می‌شود.

(ب) **ایزوتروپیک کردن فضا (Isotropic Space):** استانداردسازی باعث می‌شود مقیاس تمامی ویژگی‌ها هم‌ارز شود تا بردارهای تکین استخراج‌شده، صرفاً بر اساس همبستگی ($Correlation$) واقعی میان متغیرها تعیین شوند، نه بر اساس واحد اندازه‌گیری آن‌ها.

۶. **در برخورد با ماتریس‌های بزرگ، یکی از روش‌های تجزیه کارآمد، Randomized SVD است. ضمن ارائه شبهه کد این الگوریتم، نحوه عملکرد و کاربردهای آن را تشریح کنید.**

نحوه عملکرد و مبانی ریاضی Randomized SVD:
الگوریتم‌های کلاسیک SVD (مانند Golub-Reinsch) دارای پیچیدگی زمانی از مرتبه $\mathcal{O}(mn^2)$ هستند که برای ماتریس‌های عظیم غیرعملی است. رویکرد تصادفی بر پایه این قضیه استوار است که با تصویر کردن یک ماتریس به یک زیرفضای تصادفی کم‌بعد، ساختار طیفی غالب (Dominant Spectral Structure) ماتریس با احتمال بسیار بالا حفظ می‌شود.

این روش از دو مرحله اصلی تشکیل شده است:

(آ) ساختن یک زیرفضای متعامد (Orthogonal Subspace) که دامنه (Range) ماتریس اصلی را تقریب می‌زند.
(ب) تصویر کردن ماتریس اصلی روی این زیرفضا و محاسبه SVD قطعی (Deterministic SVD) روی ماتریس بسیار کوچکتر حاصل.

شبه‌کد تفصیلی الگوریتم Randomized SVD:
فرض کنید ماتریس داده $A \in \mathbb{R}^{m \times n}$ و رتبه هدف (تعداد مقادیر تکین مورد نیاز) k است. برای افزایش دقت، از یک پارامتر بیش‌نمونه‌برداری (Oversampling) با نام p استفاده می‌کنیم (معمولاً $p = 5$ یا 10). قرار می‌دهیم $l = k + p$.

- (آ) **تولید ماتریس تصادفی:** یک ماتریس گوسی تصادفی $\Omega \in \mathbb{R}^{n \times l}$ تولید کنید.
- (ب) **ساخت زیرفضا (Sample the column space):** ماتریس تصویر را محاسبه کنید: $Y = A\Omega \in \mathbb{R}^{m \times l}$. نکته ($Power Iteration$): اگر مقادیر تکین به کندی کاهش می‌یابند، برای جداسازی بهتر، Y را به صورت $Y = (AA^T)^q A\Omega$ محاسبه کنید (معمولاً $q = 1$ یا 2).
- (ج) **متعامدسازی (Orthogonalization):** پایه متعامد ستون‌های Y را با استفاده از تجزیه QR استخراج کنید: $Y = QR$. در اینجا $Q \in \mathbb{R}^{m \times l}$ یک ماتریس متعامد است ($Q^T Q = I$).
- (د) **کاهش ابعاد ماتریس اصلی:** ماتریس A را روی پایه Q تصویر کنید تا ماتریس تقلیل‌یافته به دست آید: $B = Q^T A \in \mathbb{R}^{l \times n}$.
- (ه) **تجزیه کلاسیک ماتریس کوچک:** الگوریتم SVD استاندارد را روی ماتریس بسیار کوچک B اجرا کنید: $B = \tilde{U}\Sigma V^T$.
- (و) **بازسازی بردارهای ویژه چپ:** ماتریس نهایی U را محاسبه کنید: $U = Q\tilde{U}$.
- (ز) **تثبیت رتبه (Truncation):** تنها k ستون اول U و V و مقدار قطری اول Σ را نگه دارید تا تقریب ماتریس حاصل شود: $A \approx U_k \Sigma_k V_k^T$.

کاربردها در علوم داده و پردازش اطلاعات:

- **تحلیل معنایی پنهان (LSI):** برای یافتن ارتباط بین کلمات و اسناد در ماتریس‌های پراکنده و بسیار بزرگ Term-Document که میلیون‌ها سطر و ستون دارند.
- **فشرده‌سازی و پردازش تصویر/ویدئو:** تقریب زدن سریع فریم‌های ویدئویی با دور ریختن مقادیر تکین کوچک که نشان‌دهنده نویز هستند، در زمان واقعی (Real-time).
- **یادگیری ماشین مقیاس‌پذیر:** به عنوان مرحله پیش‌پردازش برای کاهش ابعاد سریع (PCA سریع) پیش از آموزش مدل‌های پیچیده.